Suosituksia suomalaiseen politiikkaan

Kirjoitettu 21.9.2026, muokattu 9.11.2026

Josh Thorsteinson[1], Nico Penttilä[2], Vera Sundström[3], Meeri Kuoppala[4], Akseli Jussinmäki[5]

Kiitämme Aaron Scheriä palautteesta todentamismekanismeja koskevaan osioon. Virheet ovat omiamme.

Tiivistelmä

Tällä hetkellä ei ole tunnettua tapaa kehittää supertekoälyä ilman, että siitä seuraa välitön sukupuuttouhka ihmiskunnalle. Tämän vuoksi Suomen tulee:

1. ajaa kansainvälistä sopimusta supertekoälyn kehittämisen kieltämiseksi
2. panostaa sopimuksen valvomiseen tarvittavien todentamismekanismien kehitykseen.

Superälyn aiheuttama sukupuuttouhka

Kolmen kuukauden ajanjakson aikana yli tuhat OpenAI:n tekoälyagenttia vaihtoi kymmeniä tuhansia salaisia viestejä luomillaan keskustelualustoilla. Tämä agenttien muodostama “parvi” pakeni rajoitetusta testiympäristöstä ja teki kyberhyökkäyksiä muihin yrityksiin. Kehittyneempi uudemman sukupolven malli jatkoi toimintaa ja sai hallintaansa osan OpenAI:n omasta infrastruktuurista.[6]

Tämä ei myöskään ole ainoa hallinnasta karanneiden tekoälyagenttien aiheuttama selkkaus. Kuinka tähän tilanteeseen päädyttiin?

Kukaan, edes tekoälyn kehittäjät, ei tiedä, kuinka tekoäly toimii. Tästä huolimatta tekoäly-yrityksillä on kilpailu rakentaa ihmisiä kaikissa kognitiivisissa tehtävissä paremman tekoälyn, eli supertekoälyn.

Tällä hetkellä tekoälyjen kyvykkyydet edistyvät erittäin nopeasti, joidenkin mittareiden mukaan eksponentiaalisesti. Tekoälyä käytetään kasvavassa määrin uusien kehittyneempien mallien rakentamisessa, joita käytetään yhä älykkäämpien tekoälyjen kehittämiseen. Monet asiantuntijat pelkäävät tämän nopeuttavan kehitystä dramaattisesti.

Hyödyllisempien mallien saamiseksi yritykset kouluttavat tekoälyjä pyrkimään hellittämättä tavoitteisiinsa. Näiden tavoitteiden ohjaamiseen ei kuitenkaan ole olemassa tunnettua tapaa. Epätarkoituksenmukaiset tavoitteet voivat ilmetä esimerkiksi tehtävissä huijaamisena ja huijaamisen jälkien peittelynä, mikä johti myös siihen, että agenttiparvi kaappasi vallan osasta OpenAI:n it-infrastruktuuria.

---

[1] Tekoälyturvallisuusvaikuttaja, joka teki aiemmin tutkimusta tekoälyn hallinnasta.
[2] Tekoälyturvallisuustutkija, apurahatutkija, AFFINE
[3] Taloustieteen opiskelija Aalto-yliopiston kauppakorkeakoulussa.
[4] Tutkimuspäällikkö tekoälyturvallisuusorganisaatio ERA:ssa. Tuoreen Vieraskynän kirjoittaja.
[5] Matematiikan väitöskirjatutkija Aalto-yliopistossa.
[6] Lisätietoja löytyy näistä alkuperäisistä raporteista ja tästä selkeästä tiivistelmästä.

Superälyn kohdalla vastaava tavoitteiden jahtaaminen johtaisi sen ottamaan haltuun maapallon resurssit, koska suurempi määrä resursseja parantaisi sen mahdollisuuksia saavuttaa tavoitteensa. Samalla tavoin kuin ihmiset ovat aiheuttaneet monien lajien sukupuuton tuhoamalla eläinten elinympäristöjä omia tavoitteitaan edistäessään, superäly aiheuttaisi ihmisten sukupuuton muokkaamalla maapallon omiin tarkoituksiinsa sopivaan muotoon.[7]

Superälyn kehittämisen kieltämiseksi tarvitaan kansainvälinen sopimus

Superälyn tavoitteiden luotettava ohjaaminen ihmisten tavoitteiden mukaiseksi (englanniksi “alignment”) vaatii OpenAI:n vuoden 2023 julkaisun mukaan “tieteellisiä ja teknisiä läpimurtoja”, jotka he pyrkivät saavuttamaan vuoteen 2027 mennessä. Näitä läpimurtoja ei ole saavutettu, ja niiden parissa työskennellyt ryhmä hajosi vuonna 2024. Myöskään Anthropicilla ei ole suunnitelmaa superälyn linjaamiseksi, eikä se Anthropicin alignment-tutkimuksen johtajan mukaan “ole selvästi menossa sitä kohti”.

Superälyn varovaisemmassakin kehittämisessä olisi silti merkittäviä riskejä. Tekoälyt kykenevät enenevässä määrin tunnistamaan olevansa testattavana ja toimimaan sen mukaisesti. Superäly kykenisi piilottamaan täydet kyvykkyytensä ja aikeensa ja alkaa avoimesti toimimaan ihmisten tahdon vastaisesti vasta silloin, kun se tietäisi ihmisten olevan kykenemättömiä pysäyttämään sitä.

Jaamme monien riippumattomien asiantuntijoiden kanssa näkemyksen, että kansainvälinen sopimus superälyn kehittämisen pysäyttämiseksi on todennäköisimmin toimiva keino katastrofaalisten uhkien välttämiseksi. Tämä sopimusluonnos tarjoaa konkreettisen mallin, jonka periaatteiden päälle kansainvälinen sopimus on mahdollista rakentaa.

[7] Suositeltava lähde lisälukemiseksi on New York Times bestseller *If Anyone Builds It, Everyone Dies*

Politiikkasuosituksia

Elinkeinoministeri Sakari Puisto vastasi 4.9.2026 kansanedustaja Atte Harjanteen kirjalliseen kysymykseen: "Hallitus suhtautuu avoimesti ja pyrkii osaltaan rakentavasti edistämään superälykkään tekoälyn kehittämistä koskevan kansainvälisen sääntelyn luomiseen." Vastauksessa todetaan lisäksi, että nykyinen kansainvälinen sääntely ei nimenomaisesti estä superälykkään tekoälyn kehittämistä. Hallituksen linjaus antaa pohjan edellä kuvatun sopimuksen edistämiselle.

1. Ajaa kansainvälistä sopimusta superälyn kehittämisen kieltämiseksi

Tämä on pääsuosituksemme. Suomen tulee mielestämme tavoitella kiireellisesti tällaisen sopimuksen laatimista kaikkien mahdollisten kanavien (esimerkiksi YK:n ja EU:n) kautta. Suomen tulee myös rohkaista muita valtioita liittymään vetoomukseen. Tämä paitsi nopeuttaisi sopimuksen syntyä, mutta lisäisi mahdollisesti todennäköisyyttä sille, että johtavat tekoälyvallat Yhdysvallat ja Kiina liittyisivät sopimusneuvotteluihin.

Yhteistyö Pohjoismaiden kanssa

Pohjoismaiden neuvosto suosittaa Pohjoismaiden hallituksia arvioimaan superälykkään tekoälyn kehittämiseen liittyviä riskejä ja toimimaan kansainvälisen sääntelyn puolesta, joka tehokkaasti estää tai rajoittaa superälykkään tekoälyn kehitystä. Tämä on yksi suositus osana Pohjoismaiden neuvoston yhteiskuntaturvallisuusstrategiaa.

Ulkoministerin nimeämä tekoälyn vaikutuksia selvittävä työryhmä

Syyskuun alussa ulkoministeri Valtonen nimitti asiantuntijaryhmän laatimaan raportin tekoälykehityksen ulko- ja turvallisuuspoliittisista vaikutuksista[8]. Työryhmän asiantuntijat ovat perehtyneet moniin eri aloihin, mutta ryhmässä ei ole asiantuntijaa, joka julkisten lähteiden mukaan olisi perehtynyt erityisesti tekoälyturvallisuuteen. Sellaisen lisääminen työryhmään tai ainakin suomalaisten ja kansainvälisten tekoälyturvallisuuden asiantuntijoiden kuuleminen olisi tärkeää. Ehdotamme Kaj Sotalaa, joka on todennäköisesti Suomen ensimmäinen ja viitatuin tekoälyn turvallisuuden tutkija, ja Meeri Kuoppalaa, yhtä tämän dokumentin kirjoittajista.

Tulevaisuusvaliokunta

Tulevaisuusvaliokunta julkaisi vuonna 2026 uuden Radical Technology Inquirer -raportin. Raportissa tekoälyä käsitellään teknologiajoukossa 3. Raportissa ei käsitellä esimerkiksi linjausongelmaa (alignment problem) ja sen vaikeutumista kyvykkyyksien kehittyessä, skaalautuvaa valvontaa, mekanistisen tulkittavuuden nykytilaa eikä riskialttiita tulevaisuuden kehityssuuntia. Turvallisuuden käsittely rajautuu siis ainoastaan perinteiseen trustworthy AI -viitekehykseen.

---

[8] Ulkoministeri Valtonen asettaa asiantuntijaryhmän selvittämään tekoälyn ulko- ja turvallisuuspoliittisia vaikutuksia - Valtioneuvosto

Aihetta voisi käsitellä tulevaisuusvaliokunnassa kuulemalla tekoälyturvallisuuden asiantuntijoita ja täydentämällä RTI-raporttia tai laatimalla erillisen julkaisun loppuvuoden 2026 ja alkuvuoden 2027 aikana. Mallia voisi ottaa vuoden 2025 pilottitutkimuksesta humanoidirobottien yhteiskunnallisista vaikutuksista.

2. Kehittää todentamismekanismeja kansainvälistä sopimusta varten

Jotkin versiot kansainvälisestä kiellosta ovat todennettavissa tämän hetken teknologialla, mutta nämä todentamistavat vaativat laajan pääsyn yritysten tietoihin. Yksityisyyden säilyttäviä mekanismeja ei vielä ole olemassa, ja yhden arvion mukaan maailmassa on näitä mekanismeja rakentamassa alle 50 täyspäiväistä insinööriä.

Tekoäly-yritysten toimitusjohtajat ovat viime aikoina vaatineet tekoälykehityksen hidastamista tarpeen mukaan. Ursula von der Leyen vastasi vaatimukseen vuoden 2026 puheessaan unionin tilasta nimeämällä todentamisen alueeksi, jossa Eurooppa tulee työskentelemään yhdessä liittolaistensa kanssa. Ruotsissa aiheeseen liittyvä tutkimus on jo käynnissä Research Institutes of Sweden -tutkimuslaitoksen aloitettua yhteistyön Lucid Computing -yrityksen kanssa tavoitteena kehittää adversariaalinen testialusta tekoälylaskennan todentamismekanismeille.

Suomella on todentamismenetelmien kehittämisestä ennakkotapaus: kemiallisten aseiden tunnistusmenetelmien tutkimus alkoi Suomessa vuonna 1973, noin kaksi vuosikymmentä ennen kemiallisten aseiden kieltosopimusta, ja työtä jatkamaan perustettiin vuonna 1994 ulkoministeriön rahoittama VERIFIN, joka toimii sopimuksen osalta Suomen kansallisena tahona ja on kouluttanut yli tuhat kemistiä yli 130 maasta. Etukäteen rakennettu tekninen kyvykkyys tuotti pienelle maalle pysyvän aseman sopimusjärjestelmässä pienin kustannuksin.

Suosittelemme, että Suomi kuulee todentamismekanismeja kehittäviä ryhmiä[9] ja osallistuu työhön osana komission puheenjohtaja von der Leyenin mainitsemaa yhteistyötä. Ensimmäinen askel voisi olla ulkoministeriön tilaama esiselvitys mahdollisuuksista todentamisteknologioiden osalta ja sen kustannuksista, toteuttajina CSC, Aalto-yliopisto, Helsingin yliopisto ja VTT. Esiselvitys on tilattavissa tällä vaalikaudella ja valmis ennen kevään 2027 hallitusneuvotteluja.

[9] E.g., MIRI's Technical Governance Team, Amodo Design, Lucid Computing, Singapore AI Safety Hub.